





Etudiant :
Chassot Florian

Résumé travail de Bachelor 2024
INFORMATIQUE ET SYSTÈMES DE COMMUNICATION

PROFESSEUR·ES : Ingram Sandy	
MANDANT : Tripla Inc	
CONTACT INTERNE : Cadic Jean	
ACRONYME DU PROJET : SentLLM	NO INTERNE OU FILIÈRE : ISC
ORIENTATION : Informatique Logicielle	EXPERT·ES : Van Kommer Robert, Farah Juan Carlos
OBJECTIFS DE DEV. DURABLE :  	

LLMs for Hotel Booking Bots

Ce projet vise à comprendre les sentiments des utilisateurs d'un chatbot via deux modèles de machine learning : un modèle message par message et un modèle prenant en compte l'ensemble d'une conversation.

Contexte

Tripla est une société informatique internationale basée au Japon qui fournit des solutions SaaS (Software as a Service) pour l'industrie du voyage. L'un des services de Tripla s'appelle TriplaBot. Il permet aux clients de poser des questions sur un hôtel par l'intermédiaire d'un chatbot dans l'une des quatre langues prises en charge par Tripla : japonais, anglais, coréen et chinois. Les réponses du chatbot sont choisis parmi une liste unique pour chaque hôtel.

Un aspect crucial d'un chatbot est la compréhension de l'utilisateur. Ce projet cherche à améliorer cette compréhension en ajoutant une prédiction des sentiments de l'utilisateur avec des modèles d'analyse de sentiments utilisant des LLMs (Large Language Model) et autre technique de machine learning.

Ces sentiments peuvent ensuite être utilisés pour améliorer l'expérience utilisateur, par exemple en priorisant les réponses donnant des sentiments positifs ou en passant le chat à un opérateur humain lors d'insatisfaction.



Logo de Tripla

Objectifs

Ce projet possède deux objectifs principaux :

Analyse polaire de sentiment des messages de chatbot : Ajouter un attribut de sentiment à chaque message, compatible avec les quatre langues de Tripla, indiquant si la polarité des sentiments de l'utilisateur selon l'état de l'art d'analyse de sentiment.

Analyse de la séquence des conversations : Attribuer un mot-clé de sentiment à une conversation entière en tenant compte des patterns de répétitions et de la séquence des messages. Ce mot-clé est plus libre que juste l'aspect de polarité.

Approche polaire message par message

En prenant en compte l'état de l'art et le manque de data labélisée, deux solutions principales ont été priorisées afin de réaliser l'analyse de sentiment pour chaque message : un modèle BERT finetuned et l'utilisation d'une puissante API LLM d'entreprise comme ChatGPT.

Les deux approches nécessitent la labélisation de l'ensemble de données existant, 300 conversations fournies par Tripla.

Le modèle BERT affiné présente des difficultés avec les langues multiples et a demandé de comparer plusieurs solutions, l'option de traduire chaque message en anglais pour avoir un modèle dans une langue unique a été retenue afin de minimiser les risques et d'avoir le maximum de ressources existantes. De plus, le modèle Bert a demandé d'appliquer des techniques de data augmentation et de data balancing tels que le back-translation, random-swap, random-delete.

En ce qui concerne l'LLM utilisant une API, il a fallu faire du prompt engineering avec des prompts

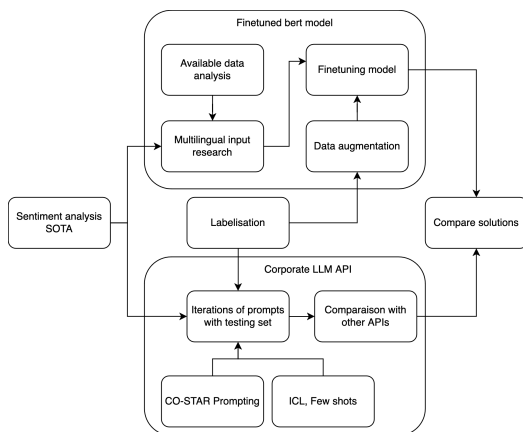


Etudiant :
Chassot Florian

Résumé travail de Bachelor 2024
INFORMATIQUE ET SYSTÈMES DE COMMUNICATION

structurés (CO-STAR) ainsi que l'inclusion d'exemple (ICL). Des comparaisons entre différents modèles sont également réalisées.

Le modèle Finetune Bert a obtenu le meilleur résultat avec 90% de précision et un F1 score de 80%.



Étape pour l'élaboration du modèle polarité

Approche séquence de conversation

Cette deuxième approche vise à déterminer le sentiment d'une conversation entière. Elle est divisée en trois grandes parties. La première consiste à générer des mots-clés liés au sentiment pour chaque conversation sans restriction. Pour ce faire, nous devons créer un prompt efficace qui génère les mots-clés et les évalue sur un échantillon de conversations. Ensuite, le prompt est utilisé sur l'ensemble des conversations de la base de données afin de générer une liste de mots-clés.

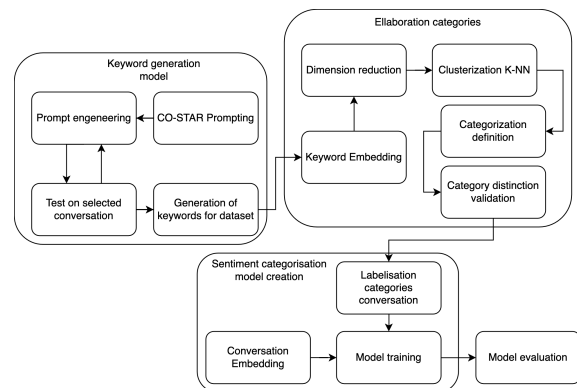
La deuxième partie consiste à créer des catégories. Les mots-clés de l'étape précédente sont transformés en vecteur (embeddings). Ensuite, ils sont regroupés en catégorie en faisant du groupement spatial (clustering). Chaque catégorie est ensuite validée en comparant la similarité entre la labélisation par plusieurs personnes en utilisant le kappa pondéré de Cohen pour déterminer si le sentiment peut être extrait de manière fiable du texte. Des 6 catégories initialement formées, 4 ont eu un score de Cohen de plus de 0.4, afin d'être retenu : positivité, frustration/insatisfaction, neutralité et curiosité.

La dernière partie est la création du modèle proprement dit. Nous utilisons les catégories

validées à l'étape précédente pour labéliser l'ensemble des conversations. Ensuite, nous vectorisons chaque conversation en tant qu'entrée d'un réseau de neurones entraîné pour prédire une des catégories.

La vectorisation est faite avec le LLM d'embedding d'OpenAI. Ces embeddings permettent d'extraire les caractéristiques d'un texte en valeur numérique, plus facile à utiliser pour faire le modèle. La compréhension du langage naturel est faite par l'embedding, le réseau de neurones doit uniquement classer les caractéristiques extraites sous forme de vecteur. C'est idéal car nous avons uniquement 300 exemples. Le taux de répétition des réponses est également rajouté au vecteur, caractéristique entraînant souvent de l'insatisfaction.

Le réseau de neurones a obtenu une précision de 84% et un F1 score de 82%.



Étape pour l'élaboration du modèle de séquence de conversation.

Résultat et travaux futurs

Le projet a permis d'explorer les LLMs et d'autres techniques de machine learning permettant de faire de l'analyse de sentiment. Il a permis de démontrer qu'il est possible de le faire dans le cadre des conversations de TriplaBot ainsi que de fournir des démarches pour créer ces modèles. L'entreprise pourra maintenant utiliser ces modèles pour améliorer l'interaction avec l'utilisateur.

Des améliorations sont possibles tels que l'entraînement sur plus de données, la validation de démarche sur un autre dataset et l'exploration d'alternative permettant de réduire le coût.